GRUPO 1

En esta primera entrega lograron integrar en un único notebook los análisis exploratorios individuales de los cinco integrantes. La presentación es clara, mantiene una estructura similar para todos los datasets y facilita la comparación entre ellos. Los análisis incluyen descripción de los datos, revisión de dimensiones, valores faltantes, estadísticas descriptivas, visualizaciones e interpretaciones. También resulta positivo que no se limitaron a mostrar gráficos, sino que identificaron problemas relevantes, como c*lases desbalanceadas, valores codificados, posibles dobles conteos y gran cantidad de datos faltantes*.

Aspectos que deben revisar

Resultados mencionados, pero no mostrados en el código: En varias interpretaciones aparecen porcentajes que no se visualizan en la salida de las celdas, por ejemplo:

- *el 72 % de la superficie correspondiente a Mendoza;*
- *el 24 % correspondiente a Malbec;*
- *el 9 % de estudiantes que juega 14 horas o más;*
- *el 86 % correspondiente al tipo de jugador 1;*
- *el 75 % de los exoplanetas detectados por tránsito.*

Es posible que los cálculos sean correctos, pero deberían quedar expresados en el código y en su salida. Esto permite verificar cómo se obtuvo cada resultado y garantiza la trazabilidad del análisis.

Dataset de adolescentes y videojuegos: Detectaron correctamente que algunas variables categóricas están representadas mediante números. Sin embargo, para interpretar esas categorías necesitan incorporar el diccionario de datos. Por ejemplo, no alcanza con señalar que `Tipo_jugador = 1` concentra el 86 % de los casos si no se explica qué representa esa categoría. Sin el diccionario, esos valores pueden utilizarse para contar casos, pero no para formular conclusiones sustantivas sobre los estudiantes.

Dataset agrícola: Es acertada la advertencia sobre las categorías que contienen la palabra "*total*", ya que podrían provocar dobles conteos. Este punto debería acompañarse con una decisión metodológica: *indicar qué categorías se excluirían o cómo se construirían los totales antes de continuar el análisis*. También deben revisar la interpretación de los valores de rendimiento igual a cero. *No puede afirmarse directamente que representan cosechas perdidas o ausencia de datos sin consultar la documentación de la fuente*. Por ahora sería más preciso presentarlos como valores que requieren validación.

Dataset de exoplanetas: Este es el dataset elegido por el grupo y presenta una dificultad importante: *varias de las variables físicas tienen porcentajes muy elevados de datos faltantes*. La masa tiene aproximadamente un 56 % de nulos, por lo que quedan cerca de 2000 registros con información disponible en esa variable. La temperatura de equilibrio, el flujo de insolación y el tipo espectral tienen todavía

menos cobertura. Por lo tanto, no alcanza con señalar que los nulos representan una oportunidad para aplicar imputación. Antes de decidir el uso del dataset deberían analizar:

- *cuántos registros completos quedarían para cada posible objetivo;*
- *qué variables se utilizarían;*
- *si la ausencia de información sigue algún patrón;*
- *si la imputación sería metodológicamente justificable;*
- *si las unidades de medida están correctamente documentadas;*
- *qué problema concreto intentarán resolver.*

La elección del dataset resulta interesante, pero actualmente está justificada principalmente por la temática y por la cantidad de variables. Falta justificar su viabilidad técnica.

Sobre las posibles aplicaciones de IA: En la conclusión se proponen tres alternativas diferentes: c*lasificar el método de descubrimiento, predecir la masa del planeta o realizar clustering*. Estas alternativas corresponden a problemas distintos y deberían evaluarse por separado.

- **Clasificar el método de descubrimiento:** deben definir cuál sería la utilidad de predecir una característica que ya aparece registrada en la base. También deben evitar utilizar variables cuya disponibilidad o medición dependa del propio método, porque podría generarse una predicción circular o poco útil.
- **Predecir la masa:** deben considerar que la variable objetivo tiene un 56 % de valores faltantes. Antes de elegir esta alternativa necesitan determinar si la cantidad y representatividad de los casos disponibles son suficientes.
- **Realizar clustering:** aparece como una alternativa posible, pero previamente deberán seleccionar variables comparables, controlar los nulos, analizar las escalas y definir qué significado tendría cada agrupamiento.

Sugiero que la conclusión incorpore una comparación explícita de estas alternativas y seleccione una sola orientación preliminar.

En términos generales, la entrega responde a la consigna y evidencia un buen trabajo de integración grupal. Los datasets cumplen con las dimensiones requeridas y cada integrante desarrolló una primera exploración acompañada por visualizaciones e interpretaciones.

Para fortalecer el trabajo, deberán homogeneizar los controles de calidad, dejar visibles los cálculos que fundamentan las conclusiones y mejorar la justificación del dataset seleccionado. En particular, antes de continuar con Exoplanetas 2021, es necesario comprobar si la cantidad de datos efectivamente utilizables permite desarrollar el problema de inteligencia artificial que elijan. La selección no debería basarse solamente en que el tema resulta atractivo, sino también en la calidad, completitud y pertinencia de los datos para el objetivo propuesto.

Las correcciones son para fortalecer el aprendizaje, eso no invalida el reconocimiento del esfuerzo realizado. ¡Felicitaciones hicieron un muy buen trabajo inicial!